

# Chapitre 1 - Ensembles de mots

Benjamin WACK (cours) - Mica MURPHY (note) - Antoine SAGET (note)

Lundi 1er Octobre 2018

## 0) Introduction

Discret est l'opposé de continu, et il peut y avoir un nombre fini ou infini de valeurs. On ne fera ni de géométrie ni d'analyse de fonctions (dérivées, etc.).

## 1) Mots

### a) Alphabets et mots

**Définition.** Un **alphabet** est un ensemble fini de symboles.

*Exemples.*

- alphabet de 26 lettres
- code ASCII
- notes de musique

**Définition.** un **mot** sur un alphabet  $A$  est une suite ordonnée finie de symboles de  $A$ .

L'ordre des lettres est important : abba est différent de baab. Il peut y avoir des répétitions.

Si  $x_1, x_2, x_n$  sont des symboles de  $A$  ; on peut parler du mot  $x = x_1x_2...x_n$

**Cas particulier.** Le **mot vide** à 0 symboles noté  $\epsilon$ .

$\epsilon$  n'est pas un symbole de  $A$

On note  $A^n$  l'ensemble des mots sur  $A$  formés de  $n$  symboles et  $A^*$  l'ensemble de tous les mots sur  $A$ .

**Définition.** On appelle **longueur d'un mot** le nombre de symboles qui le composent.

$$lg(x_1x_2...x_n) = n$$

$$lg(\epsilon) = 0$$

Dans  $A^*$  on retrouve chaque symbole de  $A$  sous la forme d'un mot de longueur 1.

*Exemples.*

- alphabet latin à 26 lettres  
Toute suite de lettres est appelée **mot** (même s'il n'est pas dans le dictionnaire)
- alphabet binaire  $B = \{0, 1\}$  Il y a  $2^n$  mots binaires de longueur  $n$ .
- alphabet des chiffres  $\{0, 1, 2, \dots, 9\}$  un mot sur cet alphabet représente un nombre entier

**Définitions.** On appelle **langage** sur  $A$  un ensemble (fini ou infini) de mots sur  $A$ , autrement dit une partie de  $A^*$ .

*Exemples.*

- Les mots du dictionnaire *Larousse 2018*
- Les suites de chiffres qui ne commencent pas par un 0.
- Le langage d'un seul mot  $\{u\}$
- $\{\epsilon\}$
- Le langage vide :  $\{\emptyset\}$  (à ne pas confondre avec  $\epsilon$  !)
- $A^*$

## b) Préfixe, suffixe, facteur

### Concaténation

Soient  $u = u_1u_2 \dots u_n$  et  $v = v_1v_2 \dots v_p$  alors le **concaténé** de  $u$  et  $v$  noté simplement  $uv$  est le mot  $u_1u_2 \dots u_nv_1v_2 \dots v_p$

*Exemple.* Si  $u = 1011$  et  $v = 010$  alors  $uv = 1011010$

### Préfixe, suffixe, facteur

Soient  $u$  et  $v$  deux mots sur  $A$ . On dit que  $u$  **est un préfixe de**  $v$  si il existe un mot  $w$  tel que  $v = uw$   
 $w$  peut être le mot vide.

On note  $u \sqsubseteq v$  le fait que  $u$  est préfixe de  $v$   $u \sqsubset v$  le fait que  $u$  est préfixe strict de  $v$  (cas où  $w \neq \epsilon$ )

**Autre caractérisation :** si  $u = u_1u_2 \dots u_n$ ,  $v = v_1v_2 \dots v_p$  alors  $u \sqsubseteq v$  si et seulement si  $u_1 = v_1, u_2 = v_2, \dots, u_n = v_n$  et  $n \leq p$

**Propriété.** Si  $u \sqsubseteq v$  et  $v \sqsubseteq u$  alors  $u = v$

**Propriété.** Si  $u \sqsubseteq v$  alors  $lg\ u \leq lg\ v$  et si  $u \sqsubset v$  alors  $lg\ u < lg\ v$

On dit que  $u$  est un :

- **suffixe** de  $v$  s'il existe un mot  $w$  tel que  $v = wu$ .
- **facteur** de  $v$  si il existe 2 mots  $x$  et  $y$  tels que  $v = xuy$

*Exemples.* Soit le mot  $baaca$  :

- ses préfixes sont  $\epsilon$ ,  $b$ ,  $ba$ ,  $baa$ ,  $baac$ ,  $baaca$ .
- ses suffixes sont  $\epsilon$ ,  $a$ ,  $ca$ ,  $aca$ ,  $aaca$ ,  $baaca$
- ses facteurs sont  $\epsilon$ ,  $b$ ,  $ba$ ,  $baa$ ,  $baac$ ,  $baaca$ ,  $a$ ,  $aa$ ,  $aac$ ,  $aaca$ ,  $ac$ ,  $aca$ ,  $c$ ,  $ca$

**Propriété.** Si  $u$  est un mot de longueur  $n$ , il admet exactement  $n + 1$  préfixes distincts,  $n + 1$  suffixes distincts et au moins  $n + 1$  facteurs (souvent plus).

### Propriétés.

- $lg(uv) = lg(u) + lg(v)$
- $lg(u^n) = n \times lg(u)$  (où  $u^n$  est le mot  $u$  répété  $n$  fois)
- $u^0 = \epsilon$

Soit  $P$  : “ $w = uv$ ” et  $Q$  : “ $lg(w) = lg(u) + lg(v)$ ” on a  $P \Rightarrow Q$ .

La réciproque ( $Q \Rightarrow P$ ) n’est pas vraie : Si  $w = uv$  alors  $lg(w) = lg(u) + lg(v)$  Si  $lg(w) = lg(u) + lg(v)$  alors  $W = uv$   
Contre-exemple :  $u = a, v = b, w = aa$

En revanche, la contraposée ( $\neg Q \Rightarrow \neg P$ ) est vraie : Si  $lg(w) \neq lg(u) + lg(v)$  alors  $w \neq uv$

### c) Distance entre mots

Soient  $u$  et  $v$  deux mots sur  $A$  de même longueur La **distance** de  $u$  à  $v$  est le nombre de symboles de  $u$  qu’il faut modifier pour obtenir  $v$ .

*Exemples.*

- $u = arbre, v = aller, d(u, v) = 4$  (seul le  $a$  est identique aux 2)
- $u = 0101110, v = 0011101, d(u, v) = 4$  (seuls 3 sur 7 caractères sont identiques aux 2)

**Propriétés.** (qui disent que  $d$  est bien une distance)

- $d(u, v) = 0$  ssi  $u = v$
- $d(u, v) = d(v, u)$
- inégalité triangulaire :  $\forall u, v, w,$

$$d(u, v) \leq d(u, w) + d(w, v)$$

**Preuve.**  $d(u, v) = \sum_{i=1}^n d(u_i, v_i)$ , d’où  $d(u, w) + d(w, v) = \sum_{i=1}^n (d(u_i, w_i) + d(w_i, v_i))$ . On peut donc se focaliser sur un seul symbole à la fois : - si  $u_i = v_i$  alors  $d(u_i, v_i) = 0 \leq d(u_i, w_i) + d(w_i, v_i)$  - si  $u_i \neq v_i$  alors  $d(u_i, v_i) = 1$  et  $w_i$  est différent d’au moins un des deux.  $d(u_i, w_i) + d(w_i, v_i) = 1 + 0$  ou  $0 + 1$  ou  $1 + 1$

## 2) Ordre lexicographique

**Idée :** comme l’ordre du dictionnaire.

Soit  $A$  un alphabet quelconque,  $A = \{a_1, a_2, \dots, a_k\}$

On dit que  $A$  est **ordonné** si on fixe un ordre  $<$  sur les symboles, par exemple,  $a_1 < a_2 < \dots < a_k$

Soient  $u$  et  $v$  deux mots de  $A^*$ ,  $u$  est **avant**  $v$  dans l’ordre lexicographique (noté  $u \leq_{\text{lex}} v$ ) si : -  $u$  est un préfixe de  $v$  OU - il existe un mot  $w$  et deux symboles  $x < y$  tels que  $wx \sqsubseteq u$  et  $wy \sqsubseteq v$

Autrement dit si  $u = u_1 u_2 \dots u_n, v = v_1 v_2 \dots v_p$  : -  $n \leq p$  et  $u_1 = v_1, \dots, u_n = v_n$  OU -  $\exists k$  tel que  $u_1 = v_1, \dots, u_k = v_k$  et  $u_{k+1} < v_{k+1}$

*Remarque.* Si  $u$  et  $v$  sont de longueur 1, les ordres  $\leq$  sur  $A$  et  $\leq_{\text{lex}}$  sur  $A^*$  coïncident.

*Exemple.* Sur  $B = \{0, 1\}$  avec  $0 < 1$ , rangeons tous les mots de longueur  $\leq 3$ : 1.  $\epsilon$  2. 0, 1 3. 00, 01, 10, 11 4. 000, 001, 010, 011, 101, 110, 111

$$\begin{aligned} \epsilon &\leq_{\text{lex}} 0 \leq_{\text{lex}} 00 \leq_{\text{lex}} 000 \leq_{\text{lex}} 001 \leq_{\text{lex}} 01 \leq_{\text{lex}} 010 \leq_{\text{lex}} 011 \\ &\leq_{\text{lex}} 1 \leq_{\text{lex}} 10 \leq_{\text{lex}} 100 \leq_{\text{lex}} 101 \leq_{\text{lex}} 11 \leq_{\text{lex}} 110 \leq_{\text{lex}} 111 \end{aligned}$$

**Propriété.**  $\leq_{\text{lex}}$  est un **ordre total** : quels que soient  $u$  et  $v \in A^*$  on a toujours  $u <_{\text{lex}}$  ou  $u >_{\text{lex}}$  ou  $u = v$ . Par exemple, ce n'est pas le cas pour  $\sqsubseteq$ .

*Remarque.* L'ordre lexicographique n'est pas commode à définir, par contre on peut écrire un **algorithme** pour décider si  $u \leq_{\text{lex}} v$  (cf. TD3)

### 3) Ensembles et dénombrement

#### a) Notion d'ensemble, fini ou infini

Un ensemble  $E$  est une collection d'éléments sans ordre ni répétition. Si  $E$  est fini, on peut le décrire explicitement par exemple  $\{a, b, c\}$  ou encore  $\{c, a, b\}$ . Cette notation est limitée : on écrit vite des ensembles comme  $\{a, b, c, \dots\}$ , ce qui est ambigu.

En général on décrit plutôt {la forme générale} de éléments de l'ensemble ou {les propriétés}.

*Exemple.*  $\{2k + 1 | k \in \mathbb{N}\} = \{1, 3, 4, 5, \dots\} \{k \in \mathbb{N} | k \text{ impair}\}$

**Notations.** -  $x \in E$  : l'élément  $x$  **appartient** à l'ensemble  $E$  -  $A \subseteq B$  : l'ensemble  $A$  est contenu / inclus dans  $B$ , autrement dit tout élément de  $A$  appartient à  $B$  -  $A \subset B$  : inclusion stricte (si  $A \subseteq B$  et  $A \neq B$ ) - l'ensemble vide  $\emptyset$  ne contient aucun élément :  $\{\}$

*Exemples.* -  $1 \in \mathbb{N}$  -  $-5 \notin \mathbb{N}$  -  $-5 \in \mathbb{Z}$  -  $\mathbb{N} \subset \mathbb{Z}$  -  $\mathbb{Z} \subseteq \mathbb{Z}$  -  $\{\epsilon\} \neq \emptyset$  -  $\{-1, 1\} \subsetneq \mathbb{N}$

*Remarque.*  $x \in E$  si et seulement si  $\{x\} \subseteq E$

**Définition.** Le **cardinal** d'un ensemble **fini** est le nombre d'éléments qui le composent, noté  $\text{card } E$ ,  $\#E$  ou  $|E|$ .

*Exemples.* -  $\text{card}(\{a, b, \dots, z\}) = 26$  -  $\text{card}(\{0, 1, \dots, 9\}) = 10$  -  $\text{card}(\{\epsilon\}) = 1$  -  $\text{card}(\emptyset) = 0$

**Attention.** Par convention, dans tout ce cours, si on parle du cardinal d'un ensemble, celui-ci est fini

*Propriétés.* - Si  $X \subseteq Y$  alors  $\text{card } X \leq \text{card } Y$  - Si  $X \subset Y$  alors  $\text{card } X < \text{card } Y$

(Notez le parallèle entre  $\subseteq, \leq$  et  $\sqsubseteq$  et entre  $\subset, <$  et  $\sqsubset$ )

#### b) Opérations entre ensembles

##### Union et intersection

L'**union** de  $X$  et  $Y$  est l'ensemble des éléments présents dans  $X$  ou  $Y$ .

$$X \cup Y = \{x | x \in X \text{ ou } x \in Y\}$$

L'**intersection** de  $X$  et de  $Y$  est l'ensemble des éléments présents la fois dans  $X$  et dans  $Y$ .

$$X \cap Y = \{x | x \in X \text{ et } x \in y\}$$

**Attention :** -  $X$  et  $Y$  sont **différents** si il existe un élément présent dans l'un mais pas dans l'autre -  $X$  et  $Y$  sont **disjoints** s'ils n'ont aucun élément commun :  $X \cap Y = \emptyset$  (disjoint est "plus fort" que différent)

*Exemples.* -  $\{0, 1\} \cup \{1, 2, 3\} = \{0, 1, 2, 3\}$  -  $\{-0, 2, 4, \dots\} \cup \{1, 3, 5, \dots\} = \mathbb{N}$  -  $\{0, 1\} \cap \{1, 2, 3\} = \{1\}$  : ils sont différents mais pas disjoints -  $\{0, 2, 4, \dots\} \cap \{1, 3, 5, \dots\} = \emptyset$  : ils sont disjoints

**Propriété.**  $\text{card}(X \cup Y) + \text{card}(X \cap Y) = \text{card } X + \text{card } Y$

*Diagramme de Venn avec union et intersection*

D'où  $\text{card } X \cup Y \leq \text{card } X + \text{card } Y$  et : on a l'égalité ssi  $X$  et  $Y$  sont disjoints. Dans ce cas on note l'union disjointe  $X \cup + Y$  ou  $X + Y$  alors  $\boxed{\text{card}(X + Y) = \text{card}(X) + \text{card}(Y)}$

### Différence

$$X \setminus Y = \{x \in X | x \notin Y\}$$

$$\text{card}(X \setminus Y) \leq \text{card } X$$

### Partition

**Définition.** Soit un ensemble  $X$  (fini ou non). On appelle **partition finie** de  $X$  :  $n$  sous-ensembles  $X_1, X_2, \dots, X_n$  deux à deux disjoints (= **exclusivité**) et dont l'union forme  $X$ .

Autrement dit : tout élément de  $X$  fait partie d'un  $X_i$  et d'un seul

*Exemple.*  $\mathbb{N}$  est partitionné en nombres pairs et nombres impairs.

$$X = X_1 + X_2 + \dots + X_n = \sum_{i=1}^n X_i$$

$$X = \bigcup_{i=1}^n X_i \text{ et } \forall i, j \text{ disjoints } X_i \cap X_j = \emptyset$$

*Exemples.* - L'ensemble des élèves d'INFO3 rangés par année de naissance. -  $\mathbb{Z}$  est partitionné en 5 parties  $(\mathbb{Z}/5\mathbb{Z}) : \{5k | k \in \mathbb{Z}\}, \{5k + 1 | k \in \mathbb{Z}\}, \{5k + 2 | k \in \mathbb{Z}\}, \{5k + 3 | k \in \mathbb{Z}\}, \{5k + 4 | k \in \mathbb{Z}\}$

### Complémentaire

Soient  $X$  et  $Y$  deux ensembles tels que  $Y \subseteq X$ . Alors  $X - Y$  ou  $C_x Y$  est le supplémentaire de  $Y$  dans  $X$ .  $\{x \in X | x \notin Y\}$  : cas particulier de différence

**Alors :** -  $Y$  et  $X - Y$  forment 2 partitions de  $X$  :

$$X = (X - Y) + Y$$

-  $\text{card } X = \text{card } (X - Y) + \text{card } Y$  -  $\boxed{\text{card } (X - Y) = \text{card } X - \text{card } Y}$  si  $Y \subseteq X$